Lilou Soulas

Le discours politique à l'épreuve de la réalité locale : une analyse quantitative du lien entre taux de chômage effectif et professions de foi dans les départements français lors des élections législatives de 1988 et 1993.

Abstract

En s'appuyant sur des méthodes de traitement automatique du langage naturel (NLP) telles que LDA et BERTopic, cet article étudie la prévalence des discours politiques sur le chômage et leur corrélation avec les taux de chômage effectifs dans les départements français lors des élections législatives de 1988 et 1993. Cette analyse est menée pour chaque orientation politique présente lors de ces scrutins. De manière générale, la thématique de l'emploi et du chômage occupe une place très réduite dans les discours politiques, ce qui conduit à une corrélation non significative entre les taux de chômage territoriaux et l'intensité des discours consacrés à ce sujet. Une corrélation n'a pu être détectée que pour les partis d'extrême Gauche, qui semblent aborder le chômage de manière plus intensive là où celui-ci est le plus élevé. Code utilisé présent en fin de projet [6].

1 Introduction

Les élections législative de 1988 et 1993 s'inscrivent dans un climat social particulièrement sombre, marqué par les conséquences durables des chocs pétroliers et une dégradation structurelle du marché du travail. Alors que la France franchit la barre symbolique des 3 millions de chômeurs, la question de l'emploi s'impose comme la préoccupation centrale des électeurs français. Dans ce contexte, le discours politique s'empare du sujet non seulement comme un défi économique, mais aussi comme un levier idéologique. On observe notamment une radicalisation des positions, illustrée par la rhétorique du *Front National* qui, dès la fin des années 70, avait cherché à établir un lien de causalité direct entre flux migratoires et hausse de l'inactivité.

Cet article se propose d'analyser la place du chômage dans les professions de foi de 1988 et 1993, années où le taux de chômage atteint respectivement 8.4 % et 9,6 % selon l'Insee. L'enjeu est de déterminer si la présence de cette thématique dans le discours électoral répond à une réalité territoriale concrète ou si elle relève d'une stratégie de communication déconnectée des indicateurs locaux. En adoptant une approche à l'échelle départementale, nous cherchons à mesurer la réactivité des candidats face aux difficultés économiques de leur propre circonscription : **le discours sur le chômage est-il proportionnel à sa réalité statistique, et cette corrélation varie-t-elle selon les familles politiques ?**

L'étude de la relation entre le contexte économique et le discours politique s'articule autour de trois piliers théoriques et méthodologiques : la théorie du vote économique, l'analyse de la rhétorique partisane et l'émergence du traitement automatique du langage.

Au cœur de la science politique, la théorie du « vote économique » postule que les conditions matérielles (croissance, inflation, chômage) influencent directement le comportement électoral. Selon

Submitted to 40th Conference on Neural Information Processing Systems (NeurIPS 2026). Do not distribute.

cette approche, les électeurs agissent comme des juges rationnels qui récompensent ou sanctionnent les responsables politiques en fonction des performances économiques nationales ou locales.

Cependant, cette réactivité n'est pas unidirectionnelle : elle dépend de la manière dont les partis politiques s'emparent de ces indicateurs. Comme le souligne la littérature sur la communication électorale, les thématiques économiques sont souvent instrumentalisées pour servir des agendas spécifiques. L'exemple historique du *Front National* en 1978, analysé par Igounet (2014) [4], montre comment une donnée brute (le chômage) est transformée en une équation politique simpliste visant à désigner un bouc émissaire (l'immigration). En 1993, alors que le chômage atteint un pic historique de 9,6 %, l'enjeu pour les partis est de transformer cette réalité sociale en un argumentaire capable de mobiliser leur base électorale respective.

L'analyse de la communication politique se heurte à la problématique du discours institutionnel formaté, souvent qualifié de « langue de bois » [5]. Ce phénomène tend à lisser les discours et à les détacher des réalités territoriales pour répondre à des impératifs de communication nationale. Étudier les tracts à une échelle locale (départementale) permet de vérifier si les candidats s'écartent de ces éléments de langage nationaux pour répondre à la situation économique spécifique de leur circonscription. Il s'agit de tester si le discours est « réactif » ou s'il reste une construction déconnectée des indicateurs de l'Insee.

Traditionnellement qualitative, l'analyse du discours politique a connu un tournant majeur avec l'introduction de méthodes quantitatives et informatiques. Grimmer et Stewart (2013) [3] ont démontré comment les techniques de Traitement Automatique du Langage (NLP) permettent de traiter des corpus massifs de textes politiques, là où une lecture humaine serait limitée. Le recours à la modélisation thématique (Topic Modeling) est devenu une norme pour identifier les préoccupations latentes d'un corpus : le modèle LDA (Latent Dirichlet Allocation), théorisé par Blei (2003) [1], constitue l'approche classique pour extraire des thèmes saillants de manière statistique. Plus récemment, des modèles basés sur le deep learning comme BERTopic permettent de capturer des nuances sémantiques plus complexes et de mieux s'adapter à la rhétorique politique, souvent riche en sous-entendus et en variations lexicales.

En croisant ces intensités thématiques calculées algorithmiquement avec les taux de chômage effectifs, cette étude s'inscrit dans une volonté de valider empiriquement si le signal détecté dans les discours électoraux de 1988 et 1993 correspond à une réalité sociologique ou à une stratégie de pure rhétorique partisane.

Pour étudier la relation entre le discours politique et la réalité du chômage, cette étude mobilise le corpus Archelec de Sciences Po [2], une archive numérique regroupant les circulaires électorales françaises. Les données analysées comprennent 3 522 tracts pour l'année 1988 et 2 120 pour 1993, couvrant l'ensemble des départements français. Après une récupération des textes par OCR, les données subissent un nettoyage approfondi (détection de la langue, filtrage alphabétique et densité des mots vides) avant d'être soumises à deux modèles thématiques : LDA, pour une approche classique du traitement du langage naturel, et BERTopic, pour mieux saisir les nuances de la rhétorique politique. Les intensités thématiques liées à l'emploi sont ensuite mises en corrélation avec les taux de chômage départementaux de l'Insee. Cette double modélisation permet de vérifier, par la comparaison des pentes de régression, si les résultats reflètent un signal réel ou un simple artefact algorithmique.

Les conclusions révèlent que la corrélation entre l'importance du chômage dans les professions de foi et le taux de chômage réel n'existe que pour les partis d'extrême Gauche. De manière générale, il y a peu de lien entre l'intensité du sujet et les chiffres officiels, et l'on note que les modèles LDA et BERTopic produisent des résultats largement convergents.

2 Données et pré-traitement

Les données de transcription ont été récupérées par le biais de requêtes sur le site `InternetArchives.org`, mais les résultats obtenus étaient partiels, soulignant ainsi la nécessité d'approfondir les techniques de nettoyage de texte. L'analyse se concentre sur les élections législatives de 1988 et 1993 en France. Après la récupération des données par OCR sur le site `InternetArchives.org`, l'échantillon avant nettoyage se compose de $N = 5837$ entrées. Cependant, une partie du texte est inutilisable en raison de défaillances de l'OCR et se compose de texte erroné (communément appelé « garbage text ») dont un exemple est donné çi dessous.

```
à nt "" x à à 5 > r.  w + C - 1, 2m - k = £.  or.  a fé Re æ L = ES AE ONCE
L eg + rm Re EL es.  > s.  - -s# 15 | y | L ‘‘ à à on Es ETS! EE e Ÿ LR -
LES ee à 7 | # FT . LS PLERMRe ‘‘ _ Fe) Re dé NS me Lie PE LS et à Pa mn | =
""à À "
```

Afin de remédier à ces problèmes de qualité, un protocole de nettoyage des données en trois étapes a été mis en place. Le texte issu de l'OCR (Optical Character Recognition) est segmenté en blocs, lesquels sont systématiquement soumis au processus suivant :

- Ratio alphabétique : cette étape évalue la proportion de lettres par rapport aux autres types de caractères afin d'écarter les blocs principalement constitués de symboles ou de chiffres.
- Vérification linguistique : un modèle de détection de langue (utilisant la bibliothèque `fasttext`) est appliqué à chaque segment de texte ; tous les blocs dont la probabilité d'être en français est inférieure à 60 % sont éliminés.
- Densité des stopwords: enfin, en s'appuyant sur la bibliothèque `spacy`, les blocs présentant une trop faible concentration de mots outils (mots de liaison indispensables à la structure des phrases en français) sont filtrés.

Le volume final de texte exploitable s'élève à $N = 2120$ entrées pour le corpus de 1993 (soit 36,3 %), tandis qu'il atteint $N = 3522$ pour celui de 1988, représentant ainsi 99,5 % des données initiales. On observe donc une disparité majeure entre ces deux années concernant la qualité et l'exploitabilité des textes récupérés.

Comme l'illustre la figure 1, une analyse préliminaire de la structure des candidatures a été effectuée. Le constat principal qui en ressort est que la majorité des données brosse le portrait-robot du candidat type aux élections législatives : il s'agit d'un homme d'âge mûr issu d'une catégorie socio-économique supérieure. Sur le plan géographique, c'est à Paris et dans les autres départements d'Île-de-France que se concentre le plus grand nombre de candidats, suivis par le Nord, l'Est et le Sud-Ouest de la France.

3 Modèles utilisés

Pour mener l'analyse thématique, deux approches distinctes ont été retenues, chacune reposant sur des hypothèses et des mécanismes statistiques différents.

3.1 Latent Dirichlet Allocation

L'Allocation de Dirichlet Latente (LDA) est une technique probabiliste de modélisation thématique dont l'idée centrale est que les documents sont constitués d'un mélange de thèmes, chaque thème étant lui-même défini comme une distribution (un mélange) de mots. Le modèle LDA calcule la probabilité qu'un mot appartienne à un thème et qu'un document contienne ce thème, en s'appuyant sur la cooccurrence et la fréquence des termes.

Cette approche repose sur l'hypothèse du « sac de mots » (bag-of-words), postulant que l'ordre des termes n'a pas d'importance et que seul leur décompte statistique permet de définir le sens. L'utilité principale du LDA réside dans sa capacité à réduire la dimensionnalité de grands corpus textuels : il permet de découvrir de manière automatisée et non supervisée les structures thématiques cachées, facilitant ainsi la classification et l'analyse de tendances au sein de volumes de données massifs que l'œil humain ne pourrait traiter seul.

3.2 BERTopic

À l'inverse, BERTopic s'appuie sur des plongements vectoriels (embeddings) pour saisir le sens sémantique des données textuelles, dépassant ainsi l'approche purement syntaxique ou statistique. Le processus débute par la vectorisation des documents à l'aide de modèles transformeurs (tels que BERT), suivie d'une réduction de la dimensionnalité des vecteurs obtenus. Enfin, des regroupements (clusters) sont identifiés pour isoler des ensembles denses de documents au sein de cet espace vectoriel réduit.

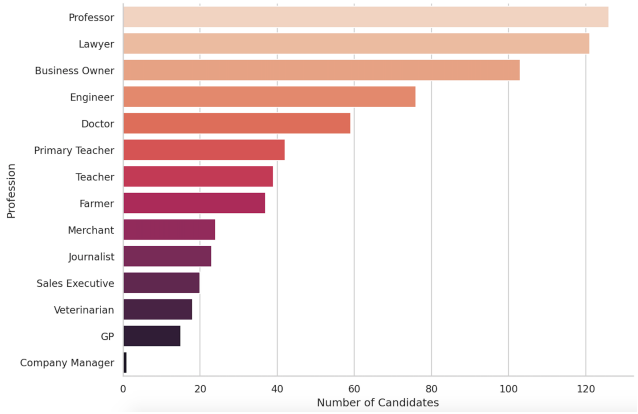

(a) Profils professionnels dominants

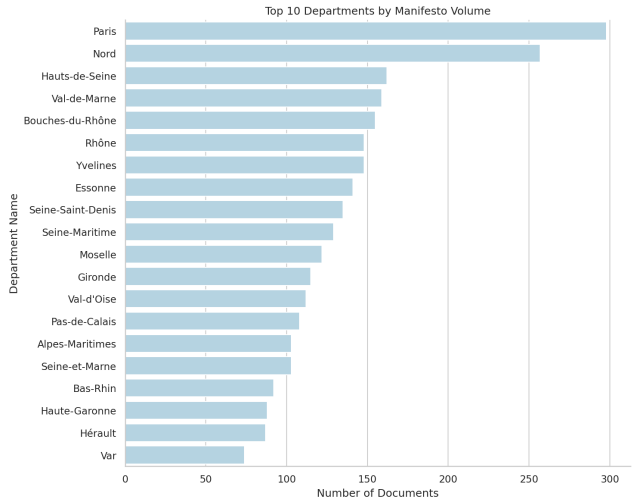

(b) Top 20 des départements par volume

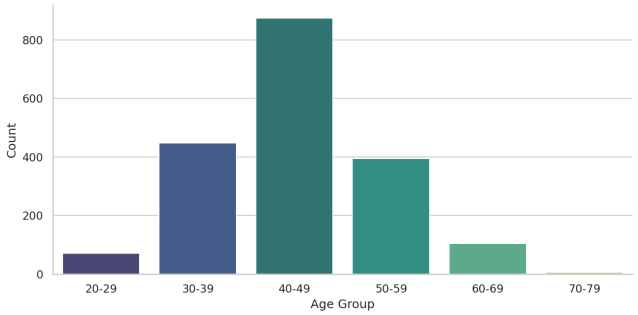

(c) Tranches d'âge des candidats

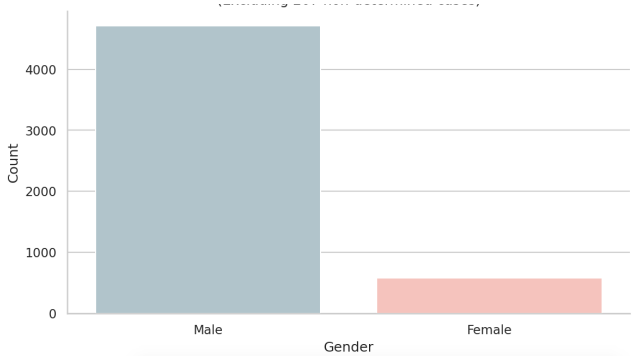

(d) Genre des candidats

Figure 1: Statistiques descriptives du dataset des candidats

Contrairement au modèle LDA, BERTopic repose sur l'hypothèse que le sens d'un mot dépend de son contexte (les mots qui l'entourent). En utilisant des transformeurs, il part du principe que des vecteurs proches dans l'espace multidimensionnel représentent des concepts sémantiquement similaires. Ce modèle est particulièrement pertinent pour traiter la rhétorique politique, car il est capable de distinguer les nuances, les métaphores et les polysémies que les modèles de "sac de mots" ignorent. De plus, sa structure modulaire permet d'ajuster finement la réduction de dimension (souvent via UMAP) et le partitionnement (via HDBSCAN), offrant une précision accrue dans l'identification de thèmes très spécifiques ou émergents.

4 Résultats et interprétation

Cette section présente les résultats issus de l'application de deux techniques de modélisation thématique (LDA et BERTopic) aux professions de foi des élections législatives françaises, ainsi que leur corrélation avec les données réelles du chômage à l'échelle départementale. Le code utilisé est accessible dans les références [6].

4.1 Résultats obtenus avec LDA

Le modèle LDA, entraîné sur l'intégralité du corpus textuel, permet d'identifier 10 thématiques et leur interprétation politique associée, présentes sur la TABLE 1 :

N°	Mots les plus fréquents	Thématique
0	français, immigration, retraite, maintenir, impôt, naturel, rétablir, vouloir, état, travail	Rhétorique politique générale
1	mars, falloir, pouvoir, homme, pays, circonscription, député, faire, candidat, savoir	Logistique électorale
2	communiste, vote, pouvoir, entendre, peuple, parti, milliard, pourcent, programme, voix	Discours de la gauche et des communistes
3	droite, gauche, écologiste, force, voter, vouloir, candidat, écologie, vendre, faire	Discours de la gauche et des communistes
4	tour, dimanche, électeur, candidat, majorité, circonscription, confiance, progrès, degré, député	Logistique électorale
5	travailleur, faire, entreprise, emploi, payer, patron, patronat, devoir, falloir, chômage	Travail, chômage et relations sociales
6	français, renaissance, ingénieur, devoir, prochain, défense, sénat, immobilier, libre, réalisme	Thématiques institutionnelles diverses
7	environnement, vie, nouveau, emploi, développement, solidarité, formation, société, monde, donner	Politiques sociales et environnementales
8	français, voix, élu, traité, entendre, taxe, peine, force, mort, front	Identité nationale et discours d'extrême droite
9	écologie, carte, argent, renouvelable, incapable, prétendre, contrôle, communautaire, abandon, mauvais	Écologie et critiques structurelles

Table 1: Mots les plus fréquents et interprétation des thématiques LDA extraites du corpus.

La thématique 5, celle qui traite du chômage, ne s'impose comme sujet dominant que dans 83 des 2 120 professions de foi de 1993, ce qui représente à peine 3,9 % du corpus. Néanmoins, lorsqu'elle prédomine, sa probabilité moyenne s'élève à 0,72, témoignant d'un signal textuel fort et cohérent au sein de ces documents. Cette faible proportion de manifestes centrés sur l'emploi constitue une

limite notable : la majorité du corpus ne traitant pas cette question de manière prioritaire, la puissance statistique des analyses de corrélation s'en trouve réduite. Cela ne signifie pas pour autant que le sujet est absent (le modèle LDA attribuant une probabilité à chaque thématique pour chaque document) mais plutôt que le chômage est rarement le pivot central du discours. L'examen de la distribution thématique révèle toutefois des limites inhérentes à l'approche LDA. On remarque notamment que les thématiques 2, 6, 8 et 9 ne sont dominantes dans aucun document, bien qu'elles aient été isolées lors de la phase d'entraînement. Cela laisse supposer que ces thématiques sont soit trop diffuses pour s'imposer individuellement, soit que le choix de 10 catégories est légèrement trop élevé par rapport à la structure réelle du corpus. Par ailleurs, la thématique 7 inclut le terme « emploi » dans ses mots-clés, créant un chevauchement partiel avec la thématique 5. Cette ambiguïté entre le discours sur le travail et les politiques sociales générales illustre une limite classique du modèle LDA, qui repose sur une indépendance stricte entre les thématiques et les mots.

4.2 Résultats obtenus avec BERTopic

Contrairement au modèle LDA, l'approche BERTopic n'assigne pas les textes à l'ensemble des thématiques, mais les regroupe au sein d'un unique cluster parmi les 19 identifiés (incluant le cluster de bruit -1, voir TABLE 2). Le fait que seuls 26 documents (soit 1,2 % du corpus) soient classés comme "bruit" suggère que le modèle est globalement satisfaisant.

Cependant, un élément frappant ressort de cette analyse : la domination excessive de la thématique 0, qui capte à elle seule 85 % des documents du corpus. Cette forte concentration dans un cluster assez générique (dont les mots-clés sont « politique », « france », « droite », « pays », « gauche ») révèle une limite importante. Cela indique une grande homogénéité du registre politique des professions de foi, que les algorithmes de partitionnement UMAP et HDBSCAN ne parviennent pas à diviser en groupes thématiques plus précis. Ce phénomène peut être mis en relation avec la notion de « langue de bois » évoquée précédemment.

La visualisation des documents confirme cette interprétation : la tache orange visible dans le document html joint montre que la majorité des textes sont très similaires, tandis que seuls quelques-uns s'en distinguent à la périphérie pour former de petits clusters isolés. De manière très nette, la thématique 0, que l'on pourrait qualifier de « politique française », est de loin la plus représentée (5052 occurences), ne laissant que de faibles effectifs aux autres catégories.

Cinq clusters peuvent être rattachés aux thématiques de l'emploi et du chômage après une vérification manuelle de leurs mots-clés. En effet, les thématiques 3, 9, 12 et 15 partagent un lexique similaire (« patrons », « travailleurs », « maintenir », « payer », « patronat », « emplois ») et correspondent essentiellement aux professions de foi du parti d'extrême Gauche *Lutte Ouvrière*. La thématique 14, définie par des termes tels que « engage », « doubler », « chômeurs » ou « compétitivité », regroupe un ensemble plus hétéroclite de tracts formulant des promesses directes de réduction du chômage. À elles cinq, ces thématiques totalisent 92 documents, soit 4,3 % du corpus, une proportion très proche de celle obtenue via le modèle LDA.

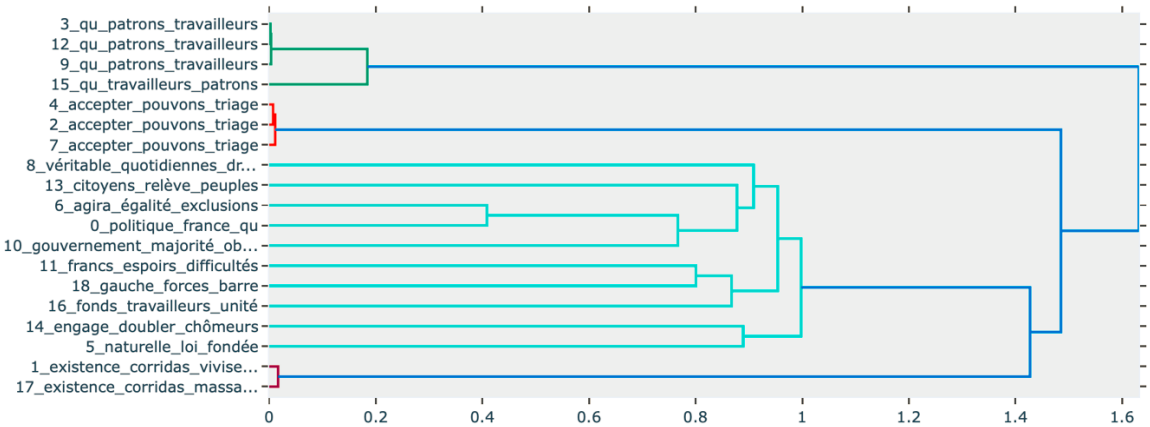

Figure 2: Regroupements hiérarchiques

La visualisation par regroupement hiérarchique présenté sur la FIGURE 2 met en lumière une structure intéressante : les thématiques 3, 9, 12 et 15 sont étroitement agrégées avec une distance quasi nulle. Cela suggère qu'elles reposent probablement sur un modèle textuel unique (le manifeste de *Lutte Ouvrière*). Ce constat soulève une interrogation méthodologique, car ces thématiques pourraient refléter la répétition d'un même tract partisan dans plusieurs circonscriptions plutôt qu'une réelle diversité thématique dans le traitement du chômage. Le modèle BERTopic s'avère particulièrement sensible à ces quasi-doublons, là où le cadre probabiliste de LDA tend à les lisser.

N°	Fréquence	Mots les plus fréquents
-1	47	voulons, qu, kofi, rôle, système, paris, vie, société, pays, présentons
0	5052	politique, france, qu, droite, ans, pays, faire, français, circonscription, gauche
1	116	existence, corridas, vivisection, véto, minimun, massacres, traitements, disposant, pratiquée, spirituelles
2	44	accepter, pouvons, triage, illusion, non, accepte, sortir, temps, production, technologies
3	38	qu, patrons, travailleurs, maintenir, payer, patronat, faire, devons, entreprises, emplois
4	27	accepter, pouvons, triage, illusion, non, accepte, sortir, temps, production, europe
5	27	naturelle, loi, fondée, cohérence, connaissance, éliminer, programme, védique, nature, système
6	23	agira, égalité, exclusions, développement, modernisera, veillera, travaillera, garantira, multipliera, désarmement
7	23	accepter, pouvons, triage, illusion, non, accepte, sortir, temps, production, technologies
8	22	véritable, quotidiennes, droite, indispensable, conviction, cni, difficultés, minée, pinay, chrétienne
9	22	qu, patrons, travailleurs, maintenir, payer, patronat, faire, devons, entreprises, emplois
10	21	gouvernement, majorité, objectifs, campagne, présidentielle, mai, ouverture, électorale, république, donner
11	20	francs, espoirs, difficultés, traditions, cœur, parti, candidats, communiste, gauche, millions
12	19	qu, patrons, travailleurs, maintenir, payer, patronat, faire, devons, entreprises, emplois
13	18	citoyens, relève, peuples, mouvement, passe, fruits, européenne, vis, présidentiel, assumer
14	15	engage, doubler, chômeurs, compétitivité, production, 000, personnes, paris, 1992, 50
15	15	qu, travailleurs, patrons, maintenir, payer, emplois, patronat, faire, entreprises, travail
16	12	fonds, travailleurs, unité, solution, école, sou, friche, ouvrière, politique, paysans
17	12	existence, corridas, massacres, vivisection, respectées, minimun, traitements, généralisé, spirituelles, abattoirs
18	11	gauche, forces, barre, ministres, affirmé, droite, rassemblement, alliance, assemblée, 1992

Table 2: Thématiques dégagées par BERTopic

4.3 Résultats obtenus avec LDA et BERTopic

À l'aide de LDA puis de BERTopic, nous pouvons étudier la corrélation entre le taux de chômage effectif et l'intensité avec laquelle les professions de foi mentionnent les thématiques liées à l'emploi. Pour ce faire, l'intensité thématique est mesurée par la probabilité assignée à la thématique 5 pour le modèle LDA, et par la somme des probabilités attribuées aux clusters 3, 9, 12, 14 et 15 pour BERTopic. Ces mesures sont agrégées à l'échelle départementale par orientation politique, puis nous calculons les corrélations de Pearson avec le taux de chômage moyen par département (données Insee). Les résultats sont détaillés dans la TABLE 3.

Orientation politique	nbr dépmts	LDA r	LDA p-value	BERTopic r	BERTopic p-value
Gauche (PS, Greens)	77	-0.001	0.992	-0.038	0.740
extrême Gauche (PCF, LO)	73	0.127	0.285	0.217	0.065
Droite (RPR, UDF)	89	0.078	0.468	-0.039	0.720
Extrême Droite (FN)	73	0.086	0.470	0.147	0.214

Table 3: Corrélation entre l'orientation politique et la distribution des thématiques déduites par LDA et BERTopic. *Les résultats indiquent des associations faibles et, pour la plupart, non significatives pour l'ensemble des groupes politiques.*

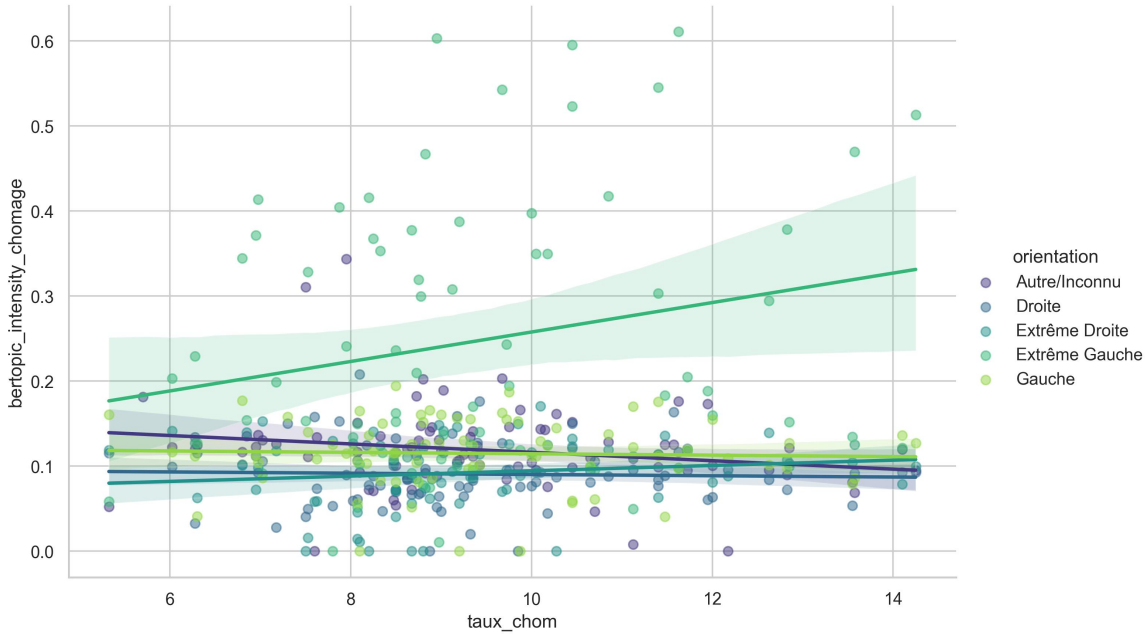

Figure 3: Corrélation entre le taux de chômage effectif et l'intensité du discours sur l'emploi et le chômage.

Les résultats révèlent une tendance constante : les corrélations s'avèrent faibles, voire négligeables, quelle que soit l'orientation politique, et aucune n'atteint les seuils de significativité conventionnels ($p < 0,05$). Le signal le plus marqué s'observe pour l'extrême Gauche (principalement le *PCF* et *Lutte Ouvrière*) avec le modèle BERTopic ($r = 0,217$; $p = 0,065$), un résultat juste au-dessus du seuil de 5 %, mais inférieur à celui de 10 %. Le diagramme de dispersion, présenté sur la FIGURE 3, confirme visuellement ce constat : la pente de régression de l'extrême Gauche est la plus accentuée, tandis que les autres formations politiques ne présentent aucune corrélation.

Concernant la Gauche (*PS*, *Les Verts*), les corrélations sont quasiment nulles pour les deux modèles (LDA : $r = -0,001$; BERTopic : $r = -0,038$). Pour la Droite (*RPR*, *UDF*), les deux modèles divergent sur le signe de la corrélation (LDA : $r = +0,078$; BERTopic : $r = -0,039$), ce qui suggère que le faible motif observé n'est pas robuste. Pour l'extrême Droite (*Front National*), une légère corrélation positive apparaît avec BERTopic ($r = 0,147$), mais elle est loin d'être significative ($p = 0,214$). Une perspective complémentaire est apportée par les scores d'intensité thématique moyenne par orientation, présents sur la TABLE 4. Les candidats d'extrême Gauche affichent, de loin, l'intensité moyenne la plus élevée dans les deux modèles (LDA : 0,234 ; BERTopic : 0,297), soit environ 10 à 15 fois plus que les candidats de Droite et de Gauche. Cela confirme que les tracts d'extrême Gauche sont non seulement plus corrélés au chômage local, mais qu'ils abordent également cette problématique avec une fréquence et une intensité nettement supérieures de manière générale.

Orientation politique	Score d'intensité moyen LDA	Score d'intensité moyen BERTopic
extrême Gauche	0.234	0.297
Gauche	0.014	0.116
Autre/Inconnu	0.026	0.115
Droite	0.016	0.090
Extrême Droite	0.008	0.096

Table 4: Intensité thématique moyenne par orientation politique pour les modèles LDA et BERTopic.

Il est assez rassurant de constater que les modèles LDA et BERTopic produisent des résultats cohérents concernant l'association de l'extrême Gauche avec le discours sur l'emploi et le chômage. En revanche, les deux modèles divergent sur le sens de la corrélation pour les autres formations politiques, ce qui en limite la généralisation.

5 Conclusion

L'objectif de cette étude était de confronter l'hypothèse du vote économique à la réalité de l'offre politique : les candidats ajustent-ils leur communication en fonction de la santé économique de leur territoire ? Nos conclusions infirment largement cette idée. Bien que la période allant de 1970 à 1990 ait été marquée par une explosion du chômage, l'analyse des professions de foi ne révèle aucune corrélation significative entre la préoccupation discursive pour l'emploi et la réalité statistique des départements.

Ce décalage tend à confirmer la thèse de Grimmer et Stewart (2013) [3], selon laquelle les campagnes législatives restent dictées par des logiques de partis nationales plutôt que par des enjeux locaux. Même l'exception observée à l'extrême Gauche doit être nuancée : elle semble davantage découler de la standardisation idéologique des tracts de *Lutte Ouvrière* que d'une adaptation fine aux besoins de l'électorat local. Pour affiner ces résultats, des recherches ultérieures pourraient explorer les variations internes au sein de chaque parti afin de mieux isoler ce qui relève du message national centralisé de ce qui tient à une éventuelle stratégie de ciblage local.

6 Limites

Ces observations ne sauraient toutefois occulter les nombreuses limites de notre travail. En premier lieu, il convient de souligner qu'aucune des corrélations analysées n'atteint le seuil de significativité statistique de 5 %, et ce, quel que soit le modèle utilisé (LDA ou BERTopic). Cette absence de significativité est en partie imputable à une puissance statistique limitée par la taille relativement réduite des échantillons à l'échelle départementale.

Deuxièmement, les résultats obtenus pour l'extrême Gauche sont quasi exclusivement portés par les tracts de *Lutte Ouvrière*. Cela suggère que ce qui est détecté localement ne reflète peut-être pas une réaction au chômage réel, mais plutôt la présence et l'implantation organisationnelle du parti sur le territoire.

Par ailleurs, la perte d'information liée aux 32 % de professions de foi classées comme « Autre/Inconnu » (en raison d'un étiquetage partisan incomplet dans les métadonnées) constitue un biais potentiel. Si ces documents non classés présentent un discours sur le chômage sensiblement différent des autres, les résultats par orientation politique pourraient s'en trouver faussés.

Enfin, la domination écrasante du cluster 0 dans le modèle BERTopic (captant 84,7 % du corpus) indique une telle homogénéité lexicale que le modèle peine à produire une structure thématique différenciée. On pourrait soutenir que ce constat constitue, en soi, un résultat scientifique : il corrobore l'idée d'une « langue de bois » où le discours politique resterait générique et déconnecté des enjeux locaux ou temporels. Néanmoins, cette uniformité limite mécaniquement la portée de nos conclusions sur les corrélations.

References

[1] David M. Blei, Andrew Y. Ng, and Michael I. Jordan. "Latent Dirichlet Allocation". In: *Journal of Machine Learning Research* 3 (2003), pp. 993–1022.

[2] Odile Gaultier-Voituriez. "Archelec, les archives électorales françaises de la Ve République, du papier au numérique : reflet fidèle ou distorsion ?" In: *La fabrique numérique des corpus en sciences humaines et sociales*. Ed. by Clarisse Bardiot, Esther Dehoux, and Emilien Ruiz. HAL Id: hal-03903314. Villeneuve-d'Ascq: Presses universitaires du Septentrion, 2022, pp. 37–45. ISBN: 9782757436103.

[3] Justin Grimmer and Brandon M. Stewart. "Text as Data: The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts". In: *Political Analysis* 21.3 (2013), pp. 267–297. DOI: 10.1093/pan/mps028.

[4] Valérie Igounet. *Le Front National Le Front National. de 1972 à nos jours. Le parti, les hommes, les idées.* Seuil. 2014. URL: https://www.seuil.com/ouvrage/le-front-national-valerie-igounet/9782021078268.

[5] Bernard Lamizet, Christian Le Bart, and Damon Mayaffre. "Le discours macroniste : un président en scène". In: *Mots. Les langages du politique* 140.1 (2026), pp. 9–16. DOI: 10.4000/162me.

[6] Lilou Soulas Lucien Chaudron Maëlie Perier. "Code utilisé dans le présent article". In: (). URL: https://github.com/LilouSoulas/Projet_NLP_Exam.git.